

Искусственный нейрон и архитектура многослойного персептрона

Основы нейронных сетей



От биологии к математике



Дендриты

Получают сигналы из окружающей среды и от других нейронов



Тело клетки


Обработывает полученные сигналы и принимает решение о возбуждении



Аксон

Передаёт результат обработки другим нейронам через синаптические связи

Искусственные нейронные сети вдохновлены устройством мозга и воспроизводят эту биологическую логику в математической форме, создавая вычислительные модели, способные обучаться на данных.



Искусственный нейрон

01

Взвешенная сумма

Нейрон принимает n входных сигналов $x_1, x_2, \dots, x_n$, умножает каждый на вес w_i и суммирует с добавлением смещения:

$$z = \sum_{i=1}^n w_i \cdot x_i + b$$

03

Выход

Формирует выходной сигнал, который передаётся на следующий слой или используется как предсказание


Здесь b — смещение (bias), позволяющее сдвигать порог активации нейрона.

02

Функция активации

Применяет нелинейную функцию к взвешенной сумме, чтобы внести нелинейность в модель:

$$y = f(z)$$



Функции активации

Функция активации вносит нелинейность в модель, без которой нейронная сеть была бы эквивалентна простой линейной модели. Выбор функции определяет свойства сети и её способность моделировать сложные зависимости.

Название	Формула	Применение
Sigmoid	$\sigma(z) = \frac{1}{1 + e^{-z}}$	Бинарная классификация
Tanh	$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	Скрытые слои (устар.)
ReLU	$f(z) = \max(0, z)$	Скрытые слои (совр.)
Softmax	$f(z_k) = \frac{e^{z_k}}{\sum_j e^{z_j}}$	Многоклассовая классификация

Многослойный персептрон (MLP)



Входной слой

Принимает признаки объекта $x \in \mathbb{R}^n$ и передаёт их на первый скрытый слой



Скрытые слои

Извлекают всё более абстрактные признаки, преобразуя входные данные через последовательные нелинейные преобразования



Выходной слой

Формирует окончательное предсказание $\hat{y}$, которое может быть классом, вероятностью или непрерывным значением

Каждый нейрон связан со всеми нейронами следующего слоя — такие слои называются полносвязными (fully connected). Глубина сети определяется количеством скрытых слоёв, а ширина — количеством нейронов в каждом слое.




FIGURE 4.1 Architectural graph of a multilayer perceptron with two hidden layers.

Прямое распространение (Forward Pass)

Для каждого слоя l вычисления записываются в матричном виде, что позволяет эффективно обрабатывать множество нейронов одновременно:

$$z^{(l)} = W^{(l)} \cdot a^{(l-1)} + b^{(l)}$$

$$a^{(l)} = f(z^{(l)})$$

$$W^{(l)}$$

Матрица весов слоя l , где каждый элемент w_{ij} определяет силу связи между i -м нейроном текущего слоя и j -м нейроном предыдущего

$$a^{(l-1)}$$

Вектор активаций предыдущего слоя, содержащий выходы всех нейронов предыдущего слоя

$$b^{(l)}$$

Вектор смещений (bias) для каждого нейрона текущего слоя, позволяющий сдвигать порог активации

$$f(\cdot)$$

Функция активации, применяемая поэлементно к вектору $z^{(l)}$, внося нелинейность в преобразование

Данные проходят последовательно от входного слоя к выходному, на каждом этапе преобразуясь через линейное преобразование и нелинейную функцию активации.

Функция потерь

Функция потерь L показывает, насколько предсказание $\hat{y}$ отличается от истинного ответа y . Минимизация функции потерь — цель процесса обучения.

Для регрессии

Среднеквадратичная ошибка (MSE) измеряет отклонение непрерывных предсказаний от истинных значений:

$$L = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

Для классификации

Кросс-энтропия измеряет качество вероятностных предсказаний:

$$L = -\frac{1}{m} \sum_{i=1}^m [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Здесь m — количество примеров в обучающем наборе, y_i — истинный ответ для i -го примера, $\hat{y}_i$ — предсказание модели.

Backpropagation — алгоритм обучения



Прямой проход

Выполняется прямое распространение → вычисляется функция потерь L



Вычисление градиентов

По правилу цепочки вычисляются градиенты потерь по весам:

$$\frac{\partial L}{\partial W^{(l)}} = \frac{\partial L}{\partial a^{(l)}} \cdot \frac{\partial a^{(l)}}{\partial z^{(l)}} \cdot \frac{\partial z^{(l)}}{\partial W^{(l)}}$$



Обновление весов

Веса обновляются методом градиентного спуска:

$$W^{(l)} \leftarrow W^{(l)} - \eta \cdot \frac{\partial L}{\partial W^{(l)}}$$

где η — скорость обучения (learning rate), определяющая размер шага при обновлении весов. Этот процесс повторяется итеративно до сходимости.

Гиперпараметры MLP

Гиперпараметры — это параметры, которые настраивает разработчик перед обучением, в отличие от весов, которые обучает модель.

Гиперпараметр	Что задаёт
Число скрытых слоёв	Глубину сети — способность модели извлекать иерархические признаки
Число нейронов в слое	Ширину сети — ёмкость каждого слоя для представления признаков
Функция активации	Тип нелинейности, вносимой в преобразования данных
Learning rate (η)	Скорость обучения — размер шага при обновлении весов
Размер батча	Сколько примеров обрабатывается за один шаг оптимизации
Число эпох	Сколько раз алгоритм проходит по всему обучающему набору

Применения MLP



Классификация изображений

Распознавание цифр, объектов и лиц на изображениях. MLP был первой архитектурой, успешно применимой к задачам компьютерного зрения.



Обработка текста

Анализ тональности отзывов, классификация документов по темам, определение намерений в тексте.



Прогнозирование

Предсказание временных рядов, финансовых показателей, спроса на товары и услугу.



Медицинская диагностика

Классификация заболеваний по табличным данным, анализ результатов анализов и медицинских показателей.



Обучение с подкреплением

Оценка ценности состояний в играх и робототехнике, предсказание вознаграждений.

MLP — фундамент, на котором выросли современные архитектуры: свёрточные сети (CNN), рекуррентные сети (RNN), трансформеры (Transformer). Понимание MLP необходимо для изучения более сложных архитектур.